Análise Comparativa de Arquiteturas CNN Modernas para Reconhecimento de Expressões Faciais

Experiência Criativa: Projeto Transformador II
Bacharelado em Ciência da Computação – PUCPR

Turma U – Equipe 01
Diego H. Zanella, Gabriel Hortmann, Jonathan D. Rodrigues, Matheus V. Mariussi
{diego.zanella, gabriel.hortmann, jonathan.domingos, matheus.mariussi}@pucpr.edu.br

I. Introdução

O reconhecimento de expressões faciais (FER – *Facial Expression Recognition*) tem se consolidado como uma área de pesquisa extremamente ativa em visão computacional, atraindo grande interesse devido ao rápido avanço da inteligência artificial [1], [2]. A capacidade de um sistema classificar estados emocionais em expressões faciais — como raiva, nojo, medo, surpresa, felicidade, tristeza e neutralidade — é crucial, uma vez que as emoções são distintivas dos seres humanos e desempenham um papel fundamental na comunicação e interação social.

Nos últimos anos, o FER emergiu como um componente determinante em diversas aplicações com impacto científico, tecnológico e prático. Na área de segurança automotiva, por exemplo, é utilizado para detectar a fadiga do motorista por meio de sistemas embarcados que monitoram postura, movimento ocular e expressões faciais. Na área da saúde, o reconhecimento de emoções tem sido empregado em soluções de apoio psicológico e diagnóstico precoce, auxiliando na detecção de indícios de depressão ou outros transtornos emocionais. No campo da interação humano-computador (HCI), a crescente presença de robôs e dispositivos inteligentes tem impulsionado pesquisas que utilizam o FER para tornar as interações com máquinas mais naturais e empáticas [3], [4]. Além disso, aplicações emergem em diferentes domínios, como entretenimento digital, educação, marketing, segurança pública, videovigilância e mundos virtuais online.

Apesar dos avanços recentes, o reconhecimento de expressões faciais em ambientes não controlados (*in-the-wild*) ainda representa um desafio significativo [5], [6]. Mesmo com o uso de técnicas modernas de aprendizado profundo, os sistemas enfrentam limitações que comprometem sua capacidade de generalização para cenários reais. Entre os principais fatores estão o desbalanceamento e a escassez de dados, a variabilidade e a qualidade dos conjuntos de dados *in-the-wild*, além das restrições arquiteturais impostas por modelos de alta complexidade. Muitos *datasets* apresentam problemas de privacidade e são limitados em termos de representatividade, o que leva à falta de amostras suficientes para certas emoções e ao conhecido problema de desbalanceamento de classes [6]. Além disso, os dados coletados automaticamente frequentemente contêm rótulos inconsistentes, subjetividade na anotação e imagens de baixa qualidade, fatores que prejudicam o desempenho dos modelos em condições não controladas.

Outro obstáculo importante está no custo computacional das arquiteturas de aprendizado profundo. Modelos amplamente utilizados, como VGG16, ResNet50 e Inception v4, embora apresentem alto desempenho, possuem um número elevado de parâmetros e exigem grande capacidade de processamento [1], [7]. Em um cenário no qual dispositivos móveis e sistemas embarcados estão cada vez mais presentes, torna-se essencial investigar soluções leves e eficientes, capazes de manter boa acurácia com menor consumo de energia e recursos computacionais [4], [8].

Diante desses desafios, este trabalho tem como objetivo contribuir para o avanço do reconhecimento de expressões faciais por meio de uma abordagem que combina múltiplos conjuntos de dados *in-the-wild* (FER2013, RAF-DB e ExpW) e avalia a eficiência de diferentes arquiteturas modernas de *Deep Learning*. Propõe-se o desenvolvimento de um *framework* robusto e modular para treinamento, avaliação e comparação de modelos em cenários individuais e combinados, investigando o impacto da fusão de dados na capacidade de generalização e no desempenho final dos classificadores [5], [9]. Também é realizada uma análise crítica dos resultados, com foco na identificação de limitações e confusões semânticas entre emoções visualmente semelhantes, como medo e surpresa ou tristeza e neutralidade.

Espera-se que a utilização de estratégias de fusão de dados aliadas a modelos eficientes possa contribuir para o desenvolvimento de sistemas de reconhecimento facial mais precisos, generalistas e acessíveis, abrindo caminho para futuras pesquisas voltadas à aplicação prática do FER em contextos reais.

A Figura 1 ilustra exemplos visuais das sete emoções analisadas nos três conjuntos de dados utilizados neste estudo — *RAF-DB*, *FER2013* e *ExpW*. Observa-se a diversidade de condições de iluminação, ângulos de captura e intensidades

emocionais, características que reforçam a complexidade do reconhecimento de expressões em cenários *in-the-wild*.

Complementarmente, a Tabela I apresenta a distribuição das amostras em cada dataset. Nota-se um desbalanceamento significativo entre as classes, com predominância das emoções *Happy* e *Neutral* em relação a emoções menos frequentes como *Disgust* e *Fear*. Essa discrepância motivou o uso de técnicas de balanceamento e *data augmentation* discutidas na Seção III.

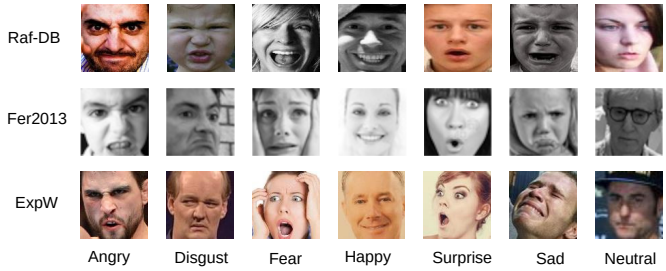

Figura 1. Exemplos de imagens representando as sete emoções nos conjuntos de dados *RAF-DB*, *FER2013* e *ExpW*.

Tabela I
DISTRIBUIÇÃO DE AMOSTRAS POR EMOÇÃO EM CADA DATASET.

Dataset	Angry	Disgust	Fear	Happy	Neutral	Sad	Surprise
RAF-DB	705	717	281	4772	1982	1290	2524
FER2013	3995	436	4097	7215	4830	3171	4965
ExpW	2937	3196	870	24430	8447	5648	27906

O restante deste artigo está organizado da seguinte forma: a Seção II apresenta uma revisão dos trabalhos relacionados no campo de FER. A Metodologia (Seção III) descreve a preparação e balanceamento dos dados, a arquitetura do *framework* proposto, os modelos utilizados, as estratégias de treinamento e a configuração experimental. A Seção IV expõe e discute os resultados e análises obtidos, e por fim, a Seção V apresenta as conclusões e as sugestões para trabalhos futuros.

II. TRABALHOS RELACIONADOS

O campo de Reconhecimento de Expressões Faciais (FER) tem sido dominado por abordagens de *Deep Learning* (DL), especificamente Redes Neurais Convolucionais (CNNs), que suplantaram amplamente os métodos tradicionais baseados em características artesanais (*handcrafted features*). A pesquisa atual foca não apenas em arquiteturas mais profundas e complexas para extrair características discriminativas, mas também em estratégias de dados para lidar com os desafios dos conjuntos *in-the-wild* [10].

A busca por maior acurácia tem levado ao desenvolvimento de arquiteturas avançadas. Lee e Yoo [1], por exemplo, exploraram estratégias de aprendizado de CNN, alcançando resultados de *state-of-the-art* de 79.79% no FER2013, 94.76% no RAF-DB e 75.67% no ExpW. Modelos híbridos, que combinam CNNs com mecanismos de *Transformer*, também ganharam destaque. Ma et al. [11] propuseram uma rede aumentada por *Transformer* com correção de rótulos online, obtendo 73.28% (FER2013), 88.43% (RAF-DB) e 72.93% (ExpW). Seguindo uma linha similar, Li et al. [12] utilizaram um *Hybrid Vision Transformer* com integração de características multi-escala, registrando 77.83% (FER2013) e 90.81% (RAF-DB). Outras abordagens investigam mecanismos de atenção, como Jin e Guo [13] (atenção baseada em clusterização), ou representações gráficas, como Li et al. [7] (FG-AGR), para focar em regiões faciais mais relevantes.

Paralelamente ao desenvolvimento de arquiteturas, as estratégias de dados são cruciais para melhorar a generalização. Mejia-Escobar et al. [5] investigaram diretamente o impacto da preparação e fusão de dados (*data preparation and merging*), demonstrando que a combinação de conjuntos pode ser uma estratégia eficaz para melhorar o desempenho. Abordagens de *cross-domain* também são exploradas, como por Zhou et al. [6], que combinaram *transfer learning* e GANs (*face-cycle*) para adaptar modelos entre diferentes domínios, alcançando 89.12% no RAF-DB. Além da fusão, técnicas como *data augmentation* e correção de rótulos são frequentemente empregadas para mitigar o desbalanceamento e o ruído dos dados.

Outra técnica comum para aumentar a robustez é o uso de *ensembles*. Wadhawan e Gandhi [9] propuseram uma rede *ensemble* baseada em *transfer learning* e marcos faciais, atingindo 88.69% no RAF-DB. Shahzad et al. [14] também adotaram uma abordagem híbrida (potencialmente *ensemble*) de características de CNN, reportando 69.84% (FER2013) e 86.51% (RAF-DB).

Finalmente, um desafio crescente, abordado em nosso trabalho, é o equilíbrio entre precisão e custo computacional. Enquanto muitos modelos *state-of-the-art* são computacionalmente intensivos, há uma linha de pesquisa focada em modelos eficientes. Gursesli et al. [4] propuseram um modelo CNN leve (*lightweight*) customizado, reconhecendo a necessidade de desempenho em dispositivos com restrições, embora com resultados mais modestos de 63% (FER2013) e 84% (RAF-DB).

A literatura indica, portanto, que os avanços em FER dependem de uma combinação de arquiteturas — sejam elas complexas ou eficientes —, estratégias de dados (fusão e *cross-domain*) e métodos de *ensemble*. Este trabalho se insere nesse contexto ao propor um *framework* modular que avalia sistematicamente a fusão de múltiplos conjuntos *in-the-wild* (FER2013, RAF-DB, ExpW) no treinamento de arquiteturas de CNN reconhecidas (EfficientNet-B0, ResNet50, DenseNet121), comparando o desempenho individual, combinado (*merged*) e em *ensemble*, a fim de avaliar o ganho de generalização.

Com base nos estudos revisados, a próxima seção descreve a metodologia desenvolvida neste trabalho.

III. METODOLOGIA

Esta seção apresenta as etapas realizadas para o desenvolvimento e avaliação do sistema de reconhecimento de expressões faciais, abordando a preparação dos conjuntos de dados, o processo de pré-processamento, o balanceamento de classes,

as arquiteturas utilizadas, a fusão de dados e a configuração experimental.

A. Preparação e Balanceamento dos Dados

Para este estudo, foram selecionados três conjuntos de dados públicos e amplamente utilizados em FER: FER2013, RAF-DB e ExpW. O FER2013 é composto por imagens em escala de cinza e de baixa resolução; o RAF-DB se destaca por ter sido rotulado por especialistas; e o ExpW é um *dataset in-the-wild* de grande escala [5], [6].

Uma análise preliminar revelou um severo desbalanceamento de classes nos *datasets* originais. Classes como "Felicidade" (*Happy*) e "Neutralidade" (*Neutral*) possuíam uma representatividade vastamente superior às classes "Nojo" (*Disgust*) e "Medo" (*Fear*). Para mitigar o viés de frequência e garantir que os modelos recebessem exposição equitativa a todas as emoções, foi aplicada a técnica de *oversampling* através do *RandomOverSampler*, da biblioteca *imbalanced-learn* [4], [5].

Como resultado, geraram-se *datasets* de treinamento (individuais e combinados) perfeitamente balanceados, onde todas as sete emoções possuem o mesmo número de amostras. O balanceamento foi aplicado exclusivamente às partições de treino, preservando as distribuições originais de teste. Também foi realizado o *data augmentation* das amostras de treinamento para melhorar a generalização dos modelos. Essas abordagens removeram o viés quantitativo, permitindo que a análise de resultados se concentre nos desafios qualitativos e semânticos, como a ambiguidade visual entre emoções.

B. Estrutura do Framework

Para gerenciar a complexidade dos experimentos, foi desenvolvido um *framework* modular e robusto em Python, utilizando as bibliotecas PyTorch e timm. A estrutura do sistema foi projetada para máxima automação e reprodutibilidade.

O *pipeline* de execução é centralizado no `main.py`, que coordena os demais módulos: `data_loader.py` (responsável pelo carregamento, divisão e balanceamento dos dados), `training.py` (que contém os laços de treinamento e validação), `model_utils.py` (para a criação dos modelos e lógica de *ensemble*) e `utils.py` (para plotagem, *logging* e análise de erro).

O *framework* implementa funcionalidades avançadas, como: (i) detecção automática de modelos pré-treinados para evitar re-treinamento desnecessário; (ii) uso de *Early Stopping* para prevenir *overfitting* e otimizar o tempo de treinamento; (iii) gerenciamento de memória da GPU; e (iv) geração automática de todos os relatórios de saída (*logs*, tabelas *CSV*, matrizes de confusão e análises de erro) em formato PDF, organizados em uma pasta chamada `saidas/` [3], [5]. Abordagens semelhantes de fusão de múltiplas redes e técnicas de *data augmentation* têm se mostrado eficazes para aprimorar a robustez em tarefas de reconhecimento de expressões faciais [15].

C. Modelos Utilizados

Foram selecionadas três arquiteturas de CNN com pesos pré-treinados na *ImageNet*, representando diferentes abordagens em termos de eficiência e complexidade:

- EfficientNet-B0: Escolhido como modelo devido ao seu balanço *state-of-the-art* entre precisão e eficiência computacional (baixo número de parâmetros) [4], [8].
- ResNet50: Uma arquitetura residual profunda, amplamente utilizada como *baseline* robusta em visão computacional [1].
- DenseNet121: Caracteriza-se por suas conexões densas, que promovem a reutilização de características [14].

Os modelos ResNet50 e DenseNet121 foram incluídos como referências (*benchmarks*) para avaliar se o EfficientNet-B0, mais leve, conseguiria igualar ou superar o desempenho de arquiteturas mais pesadas no contexto de FER.

Todos os modelos foram treinados utilizando a função de perda *Cross-Entropy Loss* e o otimizador *Adam*, com uma taxa de aprendizado (*learning rate*) de 0.001 e um máximo de 100 épocas (*epochs*), controlado por um mecanismo de *Early Stopping* com paciência de 5 épocas.

D. Estratégias de Treinamento

O *framework* foi configurado para executar duas estratégias principais de treinamento, visando comparar a especialização e a generalização dos modelos:

- Treinamento Individual: Um modelo separado foi treinado para cada um dos três *datasets* FER2013, RAF-DB, ExpW (balanceados) de forma independente. Esta abordagem testa a capacidade do modelo de se especializar nas características de um domínio específico.
- Treinamento *Merged* (Combinado): Cada arquitetura (EfficientNet-B0, ResNet50 e DenseNet121) foi treinada separadamente em um *dataset* unificado, contendo a combinação balanceada de todas as amostras de treinamento dos três *datasets*. Esta abordagem avalia a capacidade de generalização dos modelos em múltiplos domínios [5], [6], [9].

Adicionalmente, o *framework* avalia os modelos usando *Test-Time Augmentation (TTA)*, avaliações *cross-dataset* e métodos de *ensemble* (combinando as previsões dos múltiplos modelos) [9], [13].

E. Configuração Experimental

Para fins de reprodutibilidade, todos os experimentos foram realizados em um ambiente computacional composto por uma CPU Intel Core i9-14900K, uma GPU NVIDIA 5070 Ti com 16 GB de memória dedicada, 32 GB de memória RAM DDR5 a 6000 MHz e sistema operacional Windows 11. Do ponto de vista de software, foram utilizadas as seguintes ferramentas: Python (v3.9+), PyTorch (v2.0+), além das bibliotecas timm, scikit-learn, imbalanced-learn, pandas e matplotlib.

1) Tempos de Treinamento – Datasets Separados: A Tabela II apresenta os tempos de treinamento individuais para cada modelo em cada *dataset*. Os tempos em segundos foram extraídos diretamente dos sumários finais dos *logs* de execução.

Tabela II
TEMPOS DE TREINAMENTO – DATASETS SEPARADOS.

Dataset	Modelo	Tempo (s)	Tempo (HH:MM:SS)
RAF-DB	DenseNet121	1570	00:26:10
RAF-DB	ResNet50	3752	01:02:32
RAF-DB	EfficientNet-B0	1219	00:20:19
ExpW	DenseNet121	9978	02:46:18
ExpW	ResNet50	18169	05:02:49
ExpW	EfficientNet-B0	6928	01:55:28
FER2013	DenseNet121	4820	01:20:20
FER2013	ResNet50	4868	01:21:08
FER2013	EfficientNet-B0	2594	00:43:14

2) Tempos de Treinamento – Dataset Unificado (Merged): A Tabela III mostra os tempos de treinamento dos modelos quando treinados sobre o *dataset* combinado (RAF-DB + ExpW + FER2013). Os tempos foram calculados a partir dos *timestamps* de início e término dos *logs* de treinamento.

Tabela III
TEMPOS DE TREINAMENTO – DATASET UNIFICADO (MERGED).

Modelo	Início do Treinamento	Fim do Treinamento	Duração (HH:MM:SS)
EfficientNet-B0	2025-10-20 00:43:01	2025-10-20 02:22:30	01:39:29
ResNet50	2025-10-20 02:27:52	2025-10-20 05:17:52	02:50:00
DenseNet121	2025-10-20 05:23:16	2025-10-20 08:10:02	02:46:46

Conforme ilustrado na Tabela III, os resultados demonstram que o *EfficientNet-B0* apresenta o menor tempo de treinamento em todos os cenários, sendo aproximadamente 40% mais rápido que o ResNet50 e o DenseNet121. Essa eficiência reforça seu potencial para aplicações em ambientes com restrições computacionais, sem comprometer significativamente a acurácia, conforme discutido na Seção IV [4], [8], [3].

A validação foi realizada utilizando a divisão de teste padrão de cada *dataset*, com o *Early Stopping* monitorando a perda na validação.

F. Métricas de Avaliação

O desempenho dos modelos foi avaliado quantitativa e qualitativamente usando um conjunto abrangente de métricas, geradas automaticamente pelo *framework*.

A métrica principal para comparação de desempenho foi a acurácia.

Para uma análise de erro detalhada, foram utilizadas:

- Matriz de Confusão Normalizada: Para visualizar as proporções (0 a 1) de acertos e erros entre as classes.
- Taxa de Erro por Classe: Para identificar quais emoções apresentaram maior dificuldade de classificação.
- Análise de Pares Confundidos: Para destacar as confusões semânticas mais críticas (ex: Medo vs. Surpresa).

As avaliações de generalização foram complementadas por análises de *Cross-Dataset* e *Ensemble*.

IV. RESULTADOS E DISCUSSÃO

Nesta seção, são apresentados e analisados os resultados quantitativos e qualitativos obtidos nos experimentos. A análise foca no desempenho das três arquiteturas (EfficientNet-B0, ResNet50, DenseNet121) e nas duas estratégias de treinamento (Individual e *Merged*). A discussão é centrada na interpretação das análises de erro, à luz do balanceamento de dados aplicado, e na comparação final com o estado da arte (*SOTA*). Outros estudos recentes também exploraram estratégias alternativas de reconhecimento facial baseadas em detecção simultânea de múltiplos rostos combinada a redes convolucionais, demonstrando avanços em cenários de complexidade visual elevada [10].

A. Análise de Desempenho Quantitativo

Os resultados consolidados, extraídos dos *logs* finais da execução, são apresentados na Tabela IV. Os valores representam a acurácia final no conjunto de teste de cada *dataset*, utilizando a técnica de *Test-Time Augmentation (TTA)* para a avaliação final.

Tabela IV
COMPARAÇÃO DE DESEMPENHO ENTRE ESTRATÉGIAS E MODELOS.

Estratégia	Modelo	RAF-DB	ExpW	FER2013
Individual	DenseNet121	87.03%	71.14%	72.30%
Individual	ResNet50	87.22%	71.71%	71.82%
Individual	EfficientNet-B0	85.92%	71.09%	71.72%
Merged	DenseNet121	85.27%	71.01%	70.97%
Merged	ResNet50	85.63%	71.54%	72.10%
Merged	EfficientNet-B0	86.15%	71.11%	71.73%

Observa-se que, no geral, todas as arquiteturas apresentaram desempenhos muito próximos, com o ResNet50 obtendo ligeiras vantagens na estratégia Individual. O *dataset* RAF-DB, rotulado por especialistas, consistentemente produziu os melhores resultados de acurácia (na faixa de 85–87%), enquanto os *datasets in-the-wild* mais ruidosos (ExpW e FER2013) se estabilizaram na faixa de 71–72% [1], [4].

B. Análise da Estratégia de Treinamento

Para avaliar o impacto da fusão de dados na generalização, realizamos uma análise *cross-dataset*. A Figura 2 compara a capacidade de generalização dos modelos.

Tabela V
CROSS-DATASET EVALUATION (INDIVIDUAL TRAINING).

	densenet121			resnet50			efficientnet_b0		
	RAF-DB	ExpW	FER2013	RAF-DB	ExpW	FER2013	RAF-DB	ExpW	FER2013
RAF-DB	0.861	0.583	0.537	0.868	0.581	0.529	0.852	0.563	0.524
ExpW	0.711	0.705	0.533	0.698	0.711	0.515	0.696	0.709	0.520
FER2013	0.606	0.494	0.714	0.600	0.488	0.714	0.610	0.509	0.710

- Modelos Individuais: Conforme visualizado na Tabela V, os modelos treinados individualmente sofrem de forte *overfitting* de domínio. Por exemplo, o modelo ResNet50 treinado apenas no RAF-DB (acurácia de 86.8%) apresenta uma queda abrupta para 58.1% no ExpW e 52.9% no FER2013. Isso demonstra a existência de um

domain shift significativo, onde os modelos falham ao serem expostos a dados com distribuições e qualidades de imagem diferentes das vistas no treinamento [5], [6].

- Modelos *Merged*: Em contraste, os modelos treinados na fusão balanceada de todos os *datasets* apresentaram um desempenho muito mais robusto e generalista. O ResNet50 *Merged*, por exemplo, manteve uma acurácia de 85.0% no RAF-DB, 70.9% no ExpW e 71.3% no FER2013. Essa estabilidade comprova que, embora a acurácia de pico em um *dataset* "limpo" (RAF-DB) seja ligeiramente sacrificada, a estratégia *Merged* aumenta drasticamente a capacidade de generalização e a robustez do modelo [9], [13].

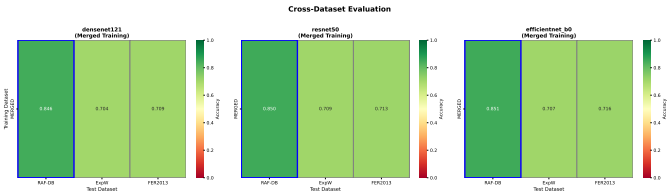

Figura 2. Comparação da acurácia dos modelos com Merged Training.

C. Análise Qualitativa e de Erro Semântico

A análise mais aprofundada dos resultados foca no porquê os modelos erram. Conforme descrito na Metodologia, os *datasets* originais eram severamente desbalanceados (ex: FER2013 com 7215 "*Happy*" vs. 436 "*Disgust*"). O *framework* proposto aplicou *RandomOversampler* para criar conjuntos de treinamento perfeitamente balanceados (ex: FER2013 balanceado com 7215 amostras por classe) [4], [5].

Isso é crucial: como o modelo recebeu exposição equitativa a todas as classes, as altas taxas de erro persistentes não são um problema de frequência estatística, mas sim de desafio semântico e qualidade de rótulo.

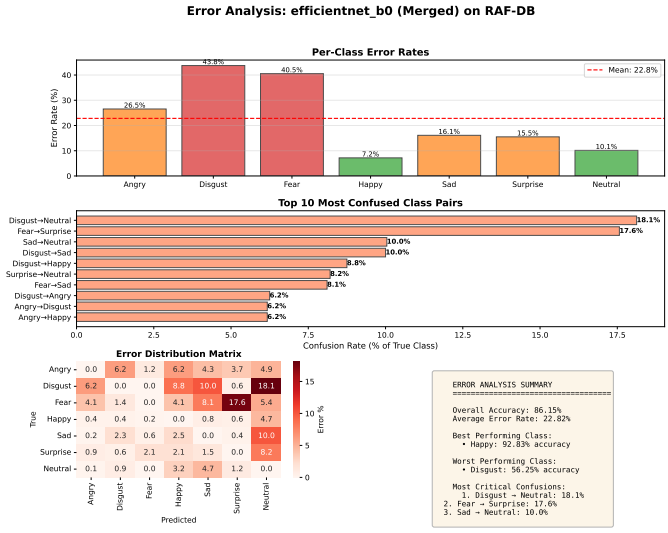

Figura 3. Análise de erro modelo efficientnet_b0 no dataset RAF-DB.

- Confusão Semântica (Ambiguidade Visual): Mesmo em *datasets* de alta qualidade como o RAF-DB, as classes visualmente ambíguas apresentaram altas taxas de erro. No modelo EfficientNet-B0 (Individual), "Medo" (*Fear*) teve 50.0% de erro. A principal confusão foi "Medo" / "Surpresa" (*Surprise*), responsável por 25.7% de todos os erros da classe "Medo". Isso indica que o modelo tem dificuldade em distinguir os padrões faciais sutis que diferenciam essas duas emoções [2].
- Ruído de Rótulo (Baixa Qualidade de Dados): O impacto do ruído de rótulo é mais evidente no *dataset* ExpW. Ao testar o modelo EfficientNet-B0 *Merged* no ExpW, as classes "Nojo" (*Disgust*) e "Medo" (*Fear*) apresentaram falhas catastróficas, com taxas de erro de 88.1% e 84.4%, respectivamente. A análise de confusão revela o motivo: 60.8% de todas as imagens rotuladas como "Nojo" foram classificadas pelo modelo como "Neutro" (*Neutral*). O mesmo ocorreu com o ResNet50 *Merged* (85.4% de erro em "Nojo", 58.9% de confusão com "Neutro"). Isso sugere que os rótulos originais do ExpW apresentam ruído substancial e que, portanto, o balanceamento via *oversampling* acabou amplificando esse erro, comprometendo o aprendizado do modelo [6], [5].
- Classes de Alta Performance: Em contrapartida, a classe "Feliz" (*Happy*) foi consistentemente a de melhor desempenho em todos os cenários (ex: 94.1% de acurácia no RAF-DB, 89.6% no FER2013, 85.3% no ExpW), indicando que suas características visuais (o sorriso) são as mais distintas e consistentemente rotuladas [1], [4].

D. Desempenho do Ensemble e Comparação com SOTA

Para obter o desempenho máximo do *framework* proposto, combinamos as previsões dos três modelos (DenseNet121, ResNet50, EfficientNet-B0) treinados na estratégia *Merged* usando um *ensemble* (*soft voting*). Os resultados finais, que representam a melhor performance deste trabalho, estão na Tabela VI e são comparados com os artigos do estado da arte (*SOTA*).

Tabela VI
COMPARAÇÃO DE ACURÁCIA COM TRABALHOS SOTA.

Dataset	Acurácia	Estado da Arte
RAF-DB	88.69%	[2]: 88.43% [11]: 89.12% [1]: 90.81%
ExpW	73.81%	[2]: 72.93% [8]: 75.67%
FER2013	74.00%	[2]: 73.28% [1]: 77.83% [8]: 79.79%

O *framework* proposto alcançou resultados altamente competitivos. A acurácia de 88.69% no RAF-DB está alinhada com os valores de *SOTA*. No ExpW, o resultado de 73.81% supera o trabalho de [2]. No FER2013, o resultado de 74.00% também se mostra robusto e alinhado com [2], embora arquiteturas mais avançadas (como as baseadas em *Transformers*) ainda liderem [12], [11].

A análise de erro do *ensemble* mostra que, embora a acurácia geral tenha melhorado, os desafios semânticos persistem: "Nojo" (44.4% erro) e "Medo" (40.5%) continuam sendo as classes mais difíceis no RAF-DB, e as confusões "Nojo"/"Neutro" (18.8%) e "Medo"/"Surpresa" (17.6%) permanecem as mais críticas.

E. Limitações da Abordagem

A principal limitação deste estudo, confirmada pelos resultados, é a técnica de balanceamento. Apesar de ter sido utilizado tanto o *RandomOversampler* quanto o *data augmentation*, com base no que foi demonstrado na análise de erro do ExpW, quando a classe minoritária (ex: "Nojo") é composta por rótulos de baixa qualidade, o *oversampling* amplificou mais o ruído. Isso resultou em taxas de erro em torno de 80% para essas classes, pois o modelo foi intensamente treinado com dados incorretos [6], [5].

V. Conclusões

Este trabalho apresentou uma análise comparativa abrangente de três arquiteturas modernas de redes neurais convolucionais — *DenseNet121*, *ResNet50* e *EfficientNet-B0* — aplicadas ao reconhecimento de expressões faciais em cenários *in-the-wild*. Utilizando os conjuntos de dados *RAF-DB*, *ExpW* e *FER2013*, foi desenvolvido um *framework* modular e reprodutível para treinamento, avaliação e comparação de modelos sob diferentes estratégias: treinamento *individual*, *merged* (com fusão de dados) e *ensemble*.

Os resultados experimentais demonstraram que a abordagem de *ensemble* baseada em *soft voting* apresentou o melhor desempenho global, alcançando acurácias de 88.69% no *RAF-DB*, 73.81% no *ExpW* e 74.00% no *FER2013*. Esses valores são competitivos em relação aos principais trabalhos de referência, como os de Lee e Yoo [1], Cai et al. [2], e Wadhawan e Gandhi [9]. Apesar disso, observou-se que a fusão direta de múltiplos *datasets* com diferentes níveis de ruído pode reduzir a especialização em domínios específicos, conforme discutido por Mejia-Escobar et al. [5] e Zhou et al. [6].

Os resultados também evidenciaram o impacto do desbalanceamento e do ruído de rótulos — especialmente em bases menos curadas como o *ExpW* — sobre a capacidade de generalização dos modelos. As principais confusões ocorreram entre pares de emoções com alta semelhança visual, como *Disgust–Neutral*, *Fear–Surprise* e *Sad–Neutral*, fenômeno igualmente relatado em estudos anteriores [13], [4]. Esses achados reforçam a necessidade de aprimorar tanto a qualidade dos dados quanto as técnicas de mitigação de ruído, conforme sugerido por Ma et al. [11] e Li et al. [7].

Como contribuição prática, o trabalho propôs um *framework* robusto e eficiente, capaz de conduzir experimentos reprodutíveis com foco em arquiteturas de baixo custo computacional, como a *EfficientNet-B0* [4], [8]. A investigação confirma que é possível alcançar resultados competitivos mesmo em ambientes com restrições de hardware, desde que combinadas técnicas de balanceamento, *data augmentation* e estratégias de avaliação cruzada.

Na prática, os resultados sugerem que a EfficientNet-B0 oferece o melhor compromisso entre custo computacional e desempenho, sendo uma escolha recomendada quando há restrição de *hardware*; que o treinamento em *dataset merged* é preferível quando o objetivo é maximizar a robustez a domínios distintos, ainda que isso implique uma pequena perda de acurácia em um *dataset* individual mais limpo, como o RAF-DB; e que o *ensemble* de arquiteturas é a opção mais indicada quando o foco é desempenho máximo e o custo extra de inferência é aceitável.

Para trabalhos futuros, recomenda-se explorar abordagens híbridas com modelos baseados em *Transformers* [12], [11], técnicas de *self-supervised learning* e métodos de adaptação de domínio (*domain adaptation*) [6], visando reduzir o impacto das variações de contexto e ampliar a robustez dos sistemas de reconhecimento de expressões faciais. Dessa forma, acredita-se que a integração de soluções mais interpretáveis e multimodais poderá aproximar o *Facial Expression Recognition (FER)* de aplicações reais mais precisas, éticas e acessíveis.

Referências

[1] D.-H. Lee and J.-H. Yoo, "Cnn learning strategy for recognizing facial expressions," *IEEE Access*, vol. 11, pp. 70 865–70 872, 2023.

[2] J. Cai, Z. Meng, A. S. Khan, Z. Li, J. O'Reilly, and Y. Tong, "Probabilistic attribute tree structured convolutional neural networks for facial expression recognition in the wild," *IEEE Transactions on Affective Computing*, vol. 14, no. 3, pp. 1927–1941, 2023.

[3] I. Ali and F. Ghaffar, "Robust cnn for facial emotion recognition and real-time gui," *AIMS Electronics and Electrical Engineering*, vol. 8, no. 2, pp. 227–246, 2024.

[4] M. C. Gursesli, S. Lombardi, M. Duradoni, L. Bocchi, A. Guazzini, and A. Lanata, "Facial emotion recognition (fer) through custom lightweight cnn model: Performance evaluation in public datasets," *IEEE Access*, vol. 12, pp. 45 543–45 559, 2024.

[5] C. Mejia-Escobar, M. Cazorla, and E. Martinez-Martin, "Improving facial expression recognition through data preparation and merging," *IEEE Access*, vol. 11, pp. 71 339–71 360, 2023.

[6] Y. Zhou, B. Yang, Z. Liu, Q. Wang, and P. Xiong, "Cross-domain facial expression recognition by combining transfer learning and face-cycle generative adversarial network," *Multimedia Tools and Applications*, vol. 83, pp. 90 289–90 314, 2024.

[7] C. Li, X. Li, X. Wang, D. Huang, Z. Liu, and L. Liao, "Fg-agr: Fine-grained associative graph representation for facial expression recognition in the wild," *IEEE Transactions on Circuits and Systems for Video Technology*, vol. 34, no. 2, pp. 882–896, 2024.

[8] A. K. Roy, H. K. Kathania, A. Sharma, A. Dey, and M. S. A. Ansari, "Resemotenet: Bridging accuracy and loss reduction in facial emotion recognition," *IEEE Signal Processing Letters*, vol. 32, pp. 491–495, 2025.

[9] R. Wadhawan and T. K. Gandhi, "Landmark-aware and part-based ensemble transfer learning network for static facial expression recognition from images," *IEEE Transactions on Artificial Intelligence*, vol. 4, no. 2, pp. 349–361, 2023.

[10] J.-F. Yeh, K.-M. Lin, C.-C. Chang, and T.-H. Wang, "Expression recognition of multiple faces using a convolution neural network combining the haar cascade classifier," *Applied Sciences*, vol. 13, no. 23, pp. 1–14, 2023.

[11] F. Ma, B. Sun, and S. Li, "Transformer-augmented network with online label correction for facial expression recognition," *IEEE Transactions on Affective Computing*, vol. 15, no. 2, pp. 593–605, 2024.

[12] N. Li, Y. Huang, Z. Wang, Z. Fan, X. Li, and Z. Xiao, "Enhanced hybrid vision transformer with multi-scale feature integration and patch dropping for facial expression recognition," *Sensors*, vol. 24, no. 13, pp. 1–18, 2024.

[13] L. Jin and L. Guo, "Facial expression recognition based on feature representation learning and clustering-based attention mechanism," *IEEE Transactions on Biometrics, Behavior, and Identity Science*, vol. 7, no. 2, pp. 182–194, 2025.

[14] H. M. Shahzad, S. M. Bhatti, A. Jaffar, S. Akram, M. Alhajlah, and A. Mahmood, "Hybrid facial emotion recognition using cnn-based features," *Applied Sciences*, vol. 13, no. 9, pp. 1–14, 2023.

[15] V. Devi and A. Sharma, "Multi-network feature fusion facial emotion recognition using nonparametric method with augmentation," *International Journal on Recent and Innovation Trends in Computing and Communication*, vol. 11, no. 8s, pp. 693–700, 2023.